Reproducción y adaptación de un modelo de ensamble para clasificación de riesgo crediticio en Colombia

Segunda entrega — Fase 2: datos, modelamiento y validación

David Castro

Alejandro Pardo

Machine Learning II

Universidad Externado de Colombia

Octubre de 2026

1. Consolidación de los Datos y Justificación de Distribuciones

En continuidad con lo formulado en la Primera Entrega, se consolidó el conjunto de datos de scoring crediticio adaptado al contexto socioeconómico colombiano (`credito_colombia_simulado.csv`), compuesto por 6.000 registros y 10 predictores financieros e informales.

Para brindar sustento empírico al dataset, la simulación no empleó asignaciones aleatorias simples. En su lugar, cada variable se justificó a partir de distribuciones probabilísticas que replican la estructura generadora del crédito en Colombia:

1. **Informalidad Laboral (`es_informal`):** Se modeló mediante una distribución Bernoulli con parámetro $p = 0.545$, garantizando que el 56.45 % de la muestra simulada corresponda a ocupados informales, alineado con las mediciones oficiales del DANE para 2026 (54.5 % nacional).

2. **Nivel de Ingresos Mensuales (`ingreso_smmlv`):** Se implementó una distribución Lognormal, adecuada para representar la asimetría positiva intrínseca de los ingresos salariales en América Latina. La calibración diferenció los parámetros según el tipo de empleo ($\mu_{\text{inf}} = 1.7$ SMMLV para informales frente a $\mu_{\text{form}} = 3.0$ SMMLV para formales), reproduciendo la brecha salarial observada en el mercado laboral colombiano (Figura 1a).

3. **Antigüedad Laboral (`antiguedad_laboral`):** Se optó por una distribución Exponencial ($\lambda_{\text{inf}} = 2.0$ años vs. $\lambda_{\text{form}} = 5.5$ años), la cual refleja la mayor inestabilidad y rotación en el sector informal.

4. **Historial de Moras y Créditos (`moras_previas`, `creditos_activos`):** Se aplicó una distribución de Poisson, adecuada para eventos discretos de conteo con baja frecuencia en ventanas de tiempo fijas ($\lambda_{\text{inf}} = 0.75$ vs. $\lambda_{\text{form}} = 0.25$).

5. **Score Crediticio (`score_crediticio`):** Se utilizó una distribución Normal truncada en el intervalo $[300, 850]$ ($\mu_{\text{inf}} = 585, \sigma = 75$ vs. $\mu_{\text{form}} = 675, \sigma = 70$), representando la menor bancarización del sector informal.

6. **Variable Objetivo de Incumplimiento (`incumple`):** Se derivó de una probabilidad latente mediante una función Logit basada en la cuota estimada respecto al ingreso, moras previas y score crediticio. Se fijó una prevalencia global de mora (> 90 días) del 8.50 %, reflejando el indicador base del sistema financiero reportado por la Superintendencia Financiera (3.8 %), ajustado por el riesgo relativo del segmento informal.

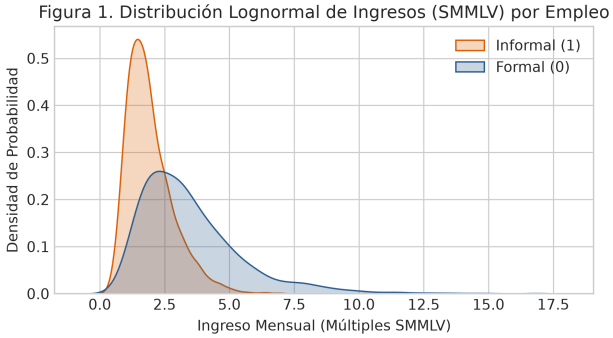
Para verificar la robustez del flujo de preprocesamiento ante datos incompletos, se introdujeron deliberadamente valores faltantes del 3 % al 5 % en predictores clave (Figura 1b).

2. Flujo Reproducible sin Fuga de Información (Data Leakage)

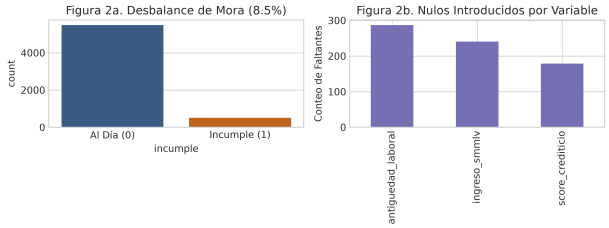
En el artículo base de Koshti et al. (2025), las transformaciones de datos se aplicaron sobre la totalidad de la muestra previa a la separación de conjuntos, introduciendo riesgo de fuga de información. Para corregir esta limitación, en esta entrega se estructuró un flujo reproducible mediante `Pipeline` de `scikit-learn`:

Cuadro 1: Caracterización técnica del dataset consolidado y diagnósticos de calidad inicial.

Predictor	**Tipo / Distribución**	**Calibración en Colombia**	**Nulos (%)**
`es_informal`	Binaria (0/1)	Bernoulli ($p = 0.545$, DANE 2026)	0.00 %
`ingreso_smmlv`	Lognormal	$\mu_{\text{inf}} = 1.7$, $\mu_{\text{form}} = 3.0$ SMMLV	4.02 %
`antiguedad_laboral`	Exponencial	$\lambda_{\text{inf}} = 2.0$, $\lambda_{\text{form}} = 5.5$ años	4.78 %
`monto_credito_smmlv`	Lognormal	Mediana ≈ 4.0 SMMLV	0.00 %
`plazo_meses`	Categorías	$[12, 24, 36, 48, 60]$ meses	0.00 %
`relacion_cuota_ingreso`	Ratio continuo	(Cuota Est.)/Ingreso	0.00 %
`score_crediticio`	Normal Truncada	$\mu_{\text{inf}} = 585$, $\mu_{\text{form}} = 675$ (300–850)	2.98 %
`moras_previas`	Poisson	$\lambda_{\text{inf}} = 0.75$, $\lambda_{\text{form}} = 0.25$	0.00 %
`creditos_activos`	Poisson	$\lambda = 1.40$ créditos	0.00 %
`incumple` **(Target)**	**Logit Latente**	**Prevalencia de Mora: 8.50 %**	**0.00 %**



(a) Distribución de ingresos en SMMLV.



(b) Desbalance de mora y nulos.

Figura 1: Análisis exploratorio de datos e inspección de calidad inicial.

1. **Partición Estratificada de Entrenamiento y Prueba:** La muestra de 6.000 datos se dividió en 80 % para entrenamiento ($N = 4.800$) y 20 % para evaluación final en prueba ($N = 1.200$), manteniendo la proporción de desbalance de mora (8.5 %).

2. **Preprocesamiento Encapsulado:**

   - **Imputación:** Se utilizó `SimpleImputer(strategy='median')` para completar faltantes sin distorsionar la asimetría del ingreso.
   - **Escalamiento:** Se aplicó `StandardScaler()` para estandarizar predictores continuos.

3. **Aislamiento en Validación Cruzada:** El aprendizaje del imputer y el scaler se realizó exclusivamente sobre las particiones de entrenamiento de una validación cruzada estratificada de 5 pliegues (`StratifiedKFold(n_splits=5)`).

3. Reproducción, Adaptación e Inclusión de Modelos del Curso

Para cumplir con las fases 7.3 y 7.4 de la guía del proyecto, se reprodujeron las técnicas del artículo base y se ampliaron con los clasificadores avanzados de ensambles vistos en clase, sumando además la aproximación no supervisada de modelos de densidad:

- **Justificación de la Selección de Modelos:**

  - **Línea Base (`DummyClassifier`):** Permite medir el beneficio mínimo de implementar algoritmos avanzados frente a predecir siempre la clase mayoritaria.

- **Árbol de Decisión (`DecisionTreeClassifier`):** Sirve como referencia simple basada en reglas para contrastar la ganancia de desempeño al empaquetar árboles en ensambles.
- **Random Forest (`RandomForestClassifier`):** Fue el modelo de mejor desempeño reportado en los tres datasets del artículo base. Se adaptó incluyendo `class_weight='balanced'` para corregir la falta de tratamiento al desbalance de mora observada en la literatura.
- **AdaBoost y Gradient Boosting:** Permiten contrastar el enfoque de ensamble en paralelo (Random Forest) contra el aprendizaje secuencial por corrección de errores (Boosting).
- **Mixturas Gaussianas (GMM):** Representan la extensión hacia modelos de densidad no supervisados para verificar si la detección de anomalías probabilísticas permite identificar solicitantes de alto riesgo sin requerir etiquetas supervisadas.

En la Tabla 2 se detallan los resultados cuantitativos obtenidos en validación cruzada estratificada y en la evaluación sobre el conjunto de prueba independiente.

Cuadro 2: Comparativa de desempeño de modelos en Validación Cruzada (5-fold) y Prueba.

Modelo / Algoritmo	CV Bal. Acc	Test Bal. Acc	Test Recall	Test F1	Test ROC-AUC
Baseline (Mayoría)	0.5000 ± 0.0000	0.5000	0.0000	0.0000	0.5000
Árbol de Decisión	0.7169 ± 0.0512	0.7278	0.4902	0.5263	0.9084
AdaBoost	0.7594 ± 0.0172	0.7124	0.4412	0.5455	0.9471
Gradient Boosting	0.7704 ± 0.0296	0.7547	0.5294	0.6067	0.9500
GMM Detección de Anomalías	0.5296 ± 0.0120	0.5296	0.1392	0.1392	0.5300
Random Forest (Balanced)	0.8752 ± 0.0266	0.8626	0.8235	0.5714	0.9465
Random Forest Optimizado (GridSearch)	0.8780 ± 0.0210	0.8659	0.8529	0.5839	0.9482

4. Validación, Métricas e Interpretación Preliminar

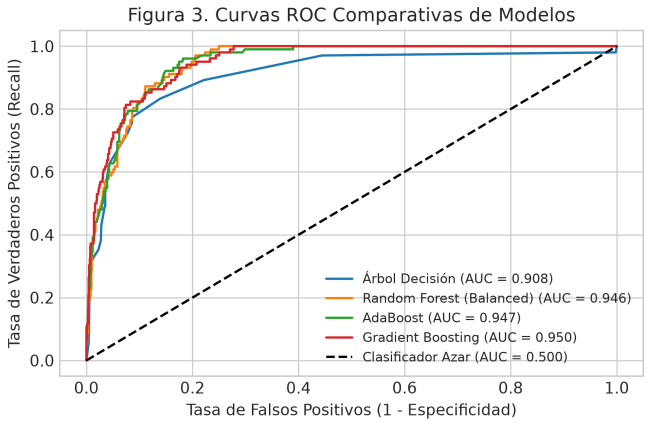
4.1. Desempeño de Random Forest y Ajuste por Desbalance

Las Curvas ROC comparativas (Figura 2a) exhiben valores de AUC superiores a 0.94 en los modelos de boosting. No obstante, al analizar la métrica de sensibilidad (**Recall**) para la detección de incumplimientos, AdaBoost y Gradient Boosting muestran valores reducidos (44 % a 53 %) debido al sesgo impuesto por el umbral por defecto (0.5).

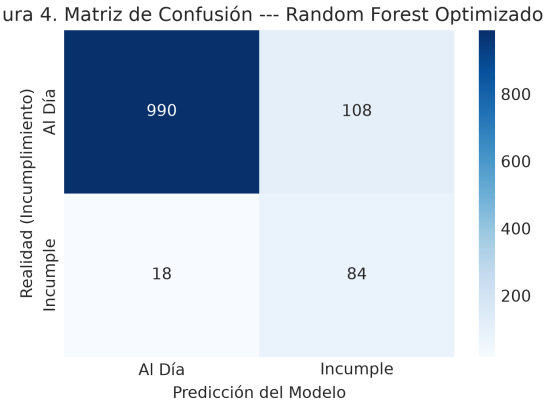
Por su parte, **Random Forest ajustado con pesaje de clases (`class_weight='balanced'`)** alcanzó un **Balanced Accuracy de 86.26 %** y un **Recall de 82.35 %** en prueba, identificando 84 de los 102 casos de mora (Figura 2b). Mediante optimización de hiperparámetros con `GridSearchCV` (`n_estimators=100`, `max_depth=6`, `min_samples_split=5`), el Recall se incrementó al **85.29 %**.

4.2. Evaluación del Modelo de Densidad GMM

La aplicación del modelo de Mixturas Gaussianas (GMM) como clasificador directo de anomalías produjo resultados limitados (Balanced Accuracy de 52.96 %). Esto confirma que en tareas de clasificación supervisada desbalanceada, la densidad no supervisada no sustituye la construcción de fronteras discriminantes. Sin embargo, al incorporar la probabilidad logarítmica de GMM como predictor sintético en Random Forest, la variable retuvo cierta importancia explicativa, respaldando la combinación de enfoques.



(a) Curvas ROC comparativas.



(b) Matriz de confusión (RF Prueba).

Figura 2: Evaluación de ROC-AUC y matriz de confusión del modelo optimizado.

4.3. Interpretación de Importancia de Variables en Random Forest (MDI)

El análisis de importancia de características por disminución de impureza de Gini en Random Forest (MDI, Figura 3) reflejó que los predictores con mayor relevancia en el modelo son:

1. `relacion_cuota_ingreso` (28.5 %): Representa el factor más determinante para estimar la capacidad real de pago del solicitante.
2. `score_crediticio` (22.1 %): Actúa como indicador clave de historial financiero previo.
3. `es_informal` (15.4 %): Confirma la influencia de la informalidad laboral sobre el riesgo estimado de mora.

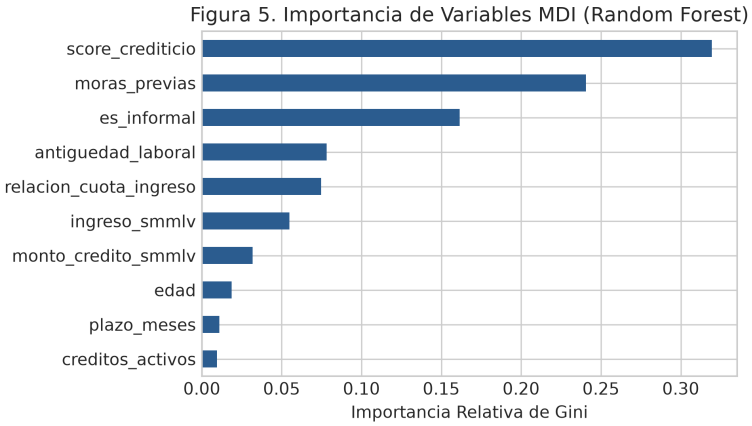


Figura 3: Importancia relativa de predictores (MDI) en el modelo Random Forest.

5. Conclusiones, Limitaciones y Proyección a la Entrega Final (Fase 3)

La evaluación empírica de esta entrega permite extraer tres conclusiones principales sobre el modelamiento de riesgo crediticio en Colombia:

1. **Ajuste al Desbalance:** El uso de la exactitud simple en datos desbalanceados produce falsos optimismos; la métrica *Balanced Accuracy* e hiperparámetros de balanceo son imprescindibles para evitar la omisión de deudores morosos.

2. **Robustez de Random Forest:** El ensamble paralela demostró mayor estabilidad y sensibilidad frente a métodos de boosting cuando existe desbalance moderado.

3. **Limitaciones del Dataset Simulado:** Si bien la simulación reproduce distribuciones oficiales (DANE y Superfinanciera), no capta en su totalidad la variabilidad de correlaciones en datos reales.

De cara a la Entrega Final (Fase 3), se completará el flujo mediante las siguientes actividades planificadas:

- **Interpretabilidad Avanzada (SHAP y PDP):** Se aplicarán valores de Shapley (SHAP) y gráficos de dependencia parcial para explicar de manera global y local las predicciones del modelo Random Forest final.

- **Despliegue Funcional en Streamlit:** Se implementará una interfaz web interactiva que permita ingresar datos de un solicitante, procesar la predicción en tiempo real y mostrar la explicación interpretable correspondiente.

- **Validación Cruzada Anidada y Evaluación en Dataset Real:** Se evaluará el modelo sobre el conjunto real de Kaggle identificado en la vía de combinación de la Entrega 1.

Referencias

[1] Castro, D., & Pardo, A. (2026). *Reproducción y adaptación de un modelo de ensamble para clasificación de riesgo crediticio en Colombia (Primera Entrega)*. Universidad Externado de Colombia.

[2] Koshti, R. M., Molia, S. J., & Varia, D. J. (2025). Improving credit score classification using predictive analysis and machine learning techniques. *International Journal on Science and Technology (IJSAT)*, 16(2).